参赛作品 • 多模态 AI 应用系统（Web 端）

AI 面试模拟系统

AI-Powered Interview Simulator

技术方案 · 全流程工程实践

FastAPI + uvicorn

Vue.js 3

PostgreSQL 16

阿里云百炼大模型服务

上传简历即可开始 · AI 全程主持 · 多模态评估报告收尾

2026 年 10 月

数据规模验证：2500+ 场模拟面试 · 2300+ 道动态题目

00 • 目录 • CONTENTS

从产品定位到工程落地：一份完整的技术方案

01 产品概述与定位

行业痛点、研发目标与差异化卡位

02 技术架构与创新

三层架构、技术选型、六大创新点

03 功能设计与实现

出题 / 语音 / 表情 / 报告全链路

04 开发测试与部署

垂直切片开发、双方案部署

05 应用价值与展望

应用场景、市场分析、成果与规划

06 附录与验证数据

数据库设计、接口清单、测试数据

真实面试稀缺、题库无法个性化——这是本产品要解决的问题

行业背景

高校应届生与初入职场者普遍缺乏真实面试经验：真人模拟面试人力成本高、时间难约、反馈质量参差不齐；题库类产品只提供静态题目，无法针对个人简历动态出题，更无法评价回答质量与临场表现。

技术条件已就绪

大模型的推理（LLM）、语音合成（TTS）、语音识别（ASR）与视觉理解（VLM）已达商用可用水平，但多数应用停留在「单一模型 + 问答框」的浅层集成，缺乏多模态协同的产品化实践。

痛点	现有方案的不足	本产品的解法
练习材料与本人经历脱节	题库刷题背八股，被追问真实项目答不上	围绕用户真实简历内容动态出题
没有口语表达练习环境	文字刷题无法训练表达能力	语音作答 + AI 面试官语音提问
缺乏临场表现反馈	无人指出表情、情绪问题	摄像头表情分析，量化临场状态
反馈笼统（“表现不错”）	无结构化改进建议	多维度评分 + 可执行改进建议

研发目标

构建「上传简历即可开始、AI 全程主持、多模态评估报告收尾」的完整模拟面试产品，验证 LLM / TTS / ASR / VLM 在真实业务闭环中的工程化落地能力。

定位：上传简历即可开始、AI 全程主持、多模态报告收尾

产品类型

AI 赋能的多模态智能应用系统（Web 端）

目标用户

高校应届毕业生 • 实习/校招求职者 • 转岗练习面试表达的初级工程师

核心功能：全流程闭环

简历上传与解析 → AI 动态出题 → 语音/文字作答 → 面试官语音提问 → 表情情绪分析 → 多维面试报告

差异化优势

优势 1

算法个性化

出题以简历内容为核心依据、岗位仅定方向，题目围绕候选人真实项目经历生成，非固定题库。

优势 2

多模态融合

同时采集文本、语音、表情三条数据通道，报告覆盖内容质量与临场表现。

优势 3

工程可靠性

语音识别、语音合成、简历解析均设计降级链路，弱网 / 额度受限场景核心功能不受影响。

三层架构：接口层 / AI 服务层 / 数据层，AI 能力统一收敛

前端层
Vue.js 3 单页应用
- **工作台 admin.html**
- **面试页 interview.html**
- **报告页 report**

接口层
FastAPI + uvicorn · REST / Bearer 鉴权
- auth / resume / interview
- report / tts / expression

AI 服务层
app/ai_services · 统一收敛
- 出题 question
- 报告 report
- 语音 speech
- 表情 expression
- 简历 resume

模型层
阿里云百炼大模型服务
- qwen-flash 文本
- qwen3-vl-flash 视觉
- cosyvoice-v3-flash 语音合成
- paraformer-realtime-v2 语音识别

数据层
PostgreSQL 16（Docker 容器）
- psycopg3 连接池
- JSONB 预留向量扩展位

数据流： Bearer 鉴权 → 简历分析落库（出题上下文）→ 出题并预生成 TTS 语音 → 表情抓拍（2.5s/帧）经 VLM 落库 → 报告聚合三类数据（答案文本 / 表情分布 / 岗位信息）

技术选型：成熟稳定、成本可控、生态兼容

类别	选型	选型依据
Web 框架	FastAPI + uvicorn	原生异步、自动 OpenAPI、Pydantic 类型校验，比 Flask 更适合 AI 接口并发
前端	Vue.js 3 + 原生组件库	单页局部刷新满足面试实时状态切换，不引入重型构建链
数据库	PostgreSQL 16（Docker）	MVCC 多写者安全、外键强制约束、JSONB 预留 pgvector；开发期 SQLite 回退
LLM	qwen-flash（百炼）	中文理解强、响应快、成本低；出题与报告共用同一配置
视觉模型	qwen3-vl-flash（百炼）	多模态表情 / 情绪判读，按帧分析成本可控
TTS	cosyvoice-v3-flash（百炼）	中文音色自然，音色 ID 精确指定面试官声线
ASR	paraformer-realtime-v2（百炼）	流式识别本地文件转写，作浏览器识别的服务端兜底
部署	Docker Compose + Nginx	容器化编排 + 反代 / SSL 终结，一条命令拉起全栈

选型原则：优先成熟稳定、成本可控、生态兼容的组件；AI 调用参数（模型名 / 端点 / 密钥）全部集中在 config.py，支持 .env 覆盖，模型更换零代码改动。

简历驱动出题 + 三通道融合评测：与同类产品的本质差异

创新点 1

简历驱动的动态出题引擎

维度	固定题库产品	本系统
出题依据	公共题库随机抽题	简历=核心依据，岗位=定方向
题目结果	人人相同	围绕真实项目，可深度追问

提示词中简历分析结果被标注为「出题核心依据」（最高权重），并明确禁止生成与简历、岗位都无关的泛概念题——与真实技术面试官的行为模式一致。

创新点 2

文本 + 语音 + 视觉三通道融合评测

通道 ① 文本	逐题回答内容 → 内容质量
通道 ② 视觉	全程表情识别记录（约 2.5s/帧）→ 情绪分布
通道 ③ 岗位	岗位维度信息 → 针对性评价

报告输出多维度评分与改进建议，将传统上只能靠真人面试官观察的「临场表现」维度量化为数据；同类产品最多做到文字回答打分。

语音双链路兜底 + TTS 双模调度：弱网下答案不丢、声音不断

创新点 3

双链路语音识别兜底

链路 A	浏览器端识别 — 零延迟、零成本，优先使用
链路 B	服务端流式识别 — paraformer-realtime-v2 转写兜底

浏览器内置识别在部分网络环境下不可用：识别失败时自动将录音打包为 WAV 上传服务端转写，答案在任何网络条件下都不会丢失。

创新点 4

TTS 预生成与实时合成双模调度

预生成	出题阶段即合成每题语音入库；面试时直接播放（毫秒级响应）
实时合成	音频缺失 / 用户换音色时自动降级；合成失败再降级浏览器内置 TTS

将「朗读等待」从秒级压缩到零感知；预生成只在出题时计费一次，复播零成本。三级降级保证「永远有声音」。

单一 Schema 权威源 + 无状态 Web 安全：工程化与安全性并重

创新点 5

单一权威 Schema 源 + 启动自动迁移

01	唯一建表脚本：表结构由单一脚本定义，无多来源漂移
02	init_db() 自动校准：应用启动时自动执行，杜绝代码与库结构漂移
03	双后端兼容：SQLite（开发）/ PostgreSQL（生产）自动切换

「代码与库结构漂移」是 AI 应用常见的部署事故源，启动自动校准从机制上杜绝了此类问题。

创新点 6

面向无状态 Web 的安全设计

01	会话凭证：服务端随机 token（secrets.token_urlsafe(32)）
02	外部寻址：不可预测 token 寻址面试记录，杜绝自增 ID 越权（IDOR）
03	敏感配置：API Key 全部走环境变量，不入代码库

服务端签发与校验凭证、Bearer 统一鉴权，所有 AI 调用挂在鉴权之后，防止匿名滥用付费模型资源。

简历解析 → 动态出题：提示词工程 + 程序化校验双层保障



AI 实现方式：双层保障

01 **第一层 • 提示词权重约定** — 简历分析结果 > 应聘岗位；出题数量与 JSON 结构与代码校验一一对应

02 **第二层 • 程序逐项校验** — LLM 返回后逐项校验，不合格自动重试兜底，保证面试一定能开始

< 2 秒
简历解析耗时（pypdf 本地提取）

1 次计费
预生成语音出题时合成，复播零成本

100%
程序校验 + 重试兜底，面试一定能开始

语音交互闭环：面试官会提问、候选人能开口、音色可选择

面试官语音 • 三级降级

① 预生成	cosyvoice-v3-flash · WAV 24kHz 入库，播放直接读取
② 实时合成	预生成缺失 / 用户换音色时降级
③ 浏览器 TTS	合成失败再降级，保证「永远有声音」

候选人作答 • 双链路

录音采集	16kHz 单声道 PCM
浏览器识别	实时转写，零延迟零成本
服务端兜底	提交时上传录音，Recognition 本地转写

6 种面试官音色

专业男 沉稳专业	**专业女** 温柔专业
亲和男 阳光友好	**亲和女** 活泼亲切
严谨男 严肃深挖	**严谨女** 干净利落

音色个性化：开始面试前可试听并锁定音色，选择结果与面试绑定；音色只影响朗读发音，不影响题目内容与评估结论。

表情分析 + 自动报告：把「临场表现」量化为数据

流程

表情情绪分析（可选，默认关闭）

01	**隐私保护**	摄像头默认关闭，用户主动开启后才采集
02	**周期抓拍**	每 2.5 秒抓拍一帧，防止并发堆积
03	**VLM 分析**	表情类别 + 情绪状态 + 情绪分，逐条落库
04	**优雅降级**	分析失败自动停止抓拍，不影响答题主流程

流程

自动面试报告

01	**LLM 逐题点评**	多维度评分 + 优势 + 可执行改进建议
02	**表情聚合**	全程情绪分布写入评估（三通道融合）
03	**结构化报告页**	前端渲染评分展示与建议
04	**报告下载**	支持导出排版后的报告文件

状态机闭环： 1 未开始 → 2 进行中 → 3 待报告 → 4 已报告，面试完成自动跳转报告页，评分流转无时序缺陷。

辅助功能与扩展性：配额商业闭环 + 四条演进路径

辅助功能（与 AI 的协同）

01 用户体系

注册 / 登录 / 登出、服务端会话 token；所有 AI 调用挂在鉴权之后，防止匿名滥用付费模型

02 配额与套餐

新用户默认 3 次面试，每次「大模型成功出题」扣 1 次；套餐购买支持沙箱对接，AI 成本与商业模型联动

03 历史记录

工作台列出全部面试（状态 / 评分 / 时间），详情页回看逐题问答与报告，构成效果度量基础

04 AI 答题提示

针对当前题目请求 AI 生成答题思路提示，练习场景的「教练模式」

扩展性设计

01 模型升级接口

模型名集中在 config.py 并支持 .env 覆盖，厂商换代零代码切换

02 多技术融合路径

数据层预留 pgvector 向量位 → 题库语义检索 + RAG；向量库统一接口，可平滑切换 Milvus

03 任务队列演进位

当前后台任务基于进程内存，规划迁移 Celery / ARQ 支撑水平扩容

04 场景扩展

出题提示词模板化（prompt.py），按岗位族扩展题风，无需改动流程代码

垂直切片开发 + 分层验证测试：九类用例全部通过

开发流程：个人全栈迭代，按「垂直切片」推进

一 **需求分析与原型** — 核心旅程定义

→ 二 **基础框架** — 三层架构 + 鉴权

→ 三 **出题链路** — 解析 → LLM 出题

→ 四 **语音链路** — TTS + 双链路 ASR

→ 五 **多模态增强** — 表情 + 报告聚合

→ 六 **工程化** — PG + Docker + 测试

核心测试用例（节选）

用例	输入	预期	结果
简历上传•合法 PDF	真实简历 PDF	200，返回面试 token	通过
简历上传•伪 DOCX	垃圾内容伪装 PK 头	422，提示解析失败	通过
出题质量	真实简历 + 目标岗位	题目围绕简历项目经历	通过
报告生成	完整面试	200，含评分与结构化建议	通过
音频转写兜底	真实 WAV（1MB）	返回完整转写文本	通过
越权防护	无 / 伪造 token	401 拦截	通过

依据测试结果的迭代优化（真实演进记录）

解析重构
多模态识别 → 文本解析 + 纯文本模型出题，从分钟级降至秒级

识别双链路
单浏览器 → 浏览器 + 服务端流式识别，弱网答案零丢失

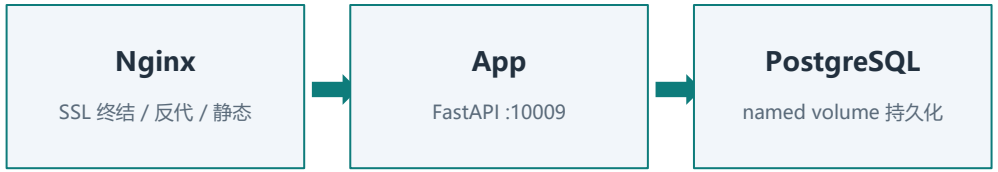
采样加密
表情抓拍 5s → 2.5s 并加防重入，采样密度翻倍

数据库迁移
SQLite → PostgreSQL 16，锁与外键问题根治，单事务原子迁移

双部署方案：一条命令拉起全栈，或解压即可完整体验

方案 A

Docker Compose（服务器长期运行）



01 docker compose up -d —— 一条命令拉起应用与数据库

02 环境变量：复制 .env.example → 填 DASHSCOPE_API_KEY、数据库密码（密钥不入库）

03 启动时自动建表 / 校准结构，无需手工迁移

04 访问 http://<host>:10009/，/docs 本地化 Swagger 离线可用

方案 B

免 Docker 轻量部署（绿色安装包）

01 **双击 setup.bat**
自动创建 venv，阿里云镜像安装依赖（约 3~5 分钟）

02 **配置 API Key**
.env 填入 DASHSCOPE_API_KEY（新账号有免费额度）

03 **双击 start_personal_server.bat**
浏览器访问 http://127.0.0.1:10009

04 **完整体验**
选音色 → 上传简历 → AI 出题 → 语音面试 → 报告

安全措施

HTTPS 全站加密 | API Key 仅存本地 .env | 服务端签发与会话校验 | 不可预测 token 外部寻址

三场景落地：单场成本压缩至分钟级等待 + AI 调用费

场景 1

场景 1 • 高校就业指导中心

学生注册 → 上传简历 → 3 分钟内获得定制面试 → 立即查看评分建议；传统线下人均需教师 30 分钟以上，使「人人可反复练」成为可能。

场景 2

场景 2 • 求职者个人自主训练

同一段简历反复练习，逐场对比报告进步；表情分析帮助改善「内容会但表现差」的隐性失分点。

场景 3

场景 3 • 培训机构 / 企业初筛

基于历史记录与评分分布定位学员共性弱点；企业校招「预演场」，降低真人面试官无效工作量。

系统真实运行验证数据

2500+
场模拟面试（interviews）

2300+
道动态生成题目

400+
条表情采样数据

17
份完整报告全链路闭环

市场分析

市场规模：2026 届全国高校毕业生规模处于千万级高位，「就业难 + 面试焦虑」构成刚性需求；AI 面试赛道同时覆盖 C 端训练与 B 端筛选，市场空间明确。

差异化卡位：个性化出题 × 多模态反馈 × 低成本可得

对比维度	静态题库产品	真人模拟面试服务	本产品
题目与个人匹配度	低（公共题库）	高	高（简历动态生成）
口语练习	无	有	有（语音作答 + AI 提问）
临场表现反馈	无	依赖面试官水平	表情情绪量化分析
成本 / 可得性	低	高（约人）	低（AI 全自动随时可练）
结构化报告	弱	不标准	多维度评分 + 可执行建议

竞争力小结

本产品在「个性化出题 × 多模态反馈 × 低成本可得」三个维度的交集上形成差异化卡位；算法层面（提示词工程 + 程序校验 + 双链路兜底）与功能层面（全流程闭环）均已通过真实运行验证。

成果总结：全流程工程实践 + 真实数据规模验证

成果总结

01 工程实践完整

三层架构 + 容器化交付 + 自动化建表迁移 + 脚本化测试体系

02 五模型协同

LLM / VLM / TTS / ASR 在同一业务闭环协同，文本 / 语音 / 视觉三通道融合评测

03 关键技术突破

简历驱动动态出题、语音双链路兜底、TTS 预生成双模调度

04 真实数据验证

2500+ 场面试、2300+ 道题目、400+ 表情样本、17 份完整报告闭环

当前不足（坦诚分析）

- 后台任务基于进程内存，重启丢失进行中任务
- 表情分析依赖云端 VLM 逐帧调用，采样与成本需权衡
- 仅 Web 端覆盖，并发能力未经过压力测试

未来规划（按优先级）

1	**任务队列**	Celery / ARQ 独立队列，出题报告异步化、可重试、可水平扩容
2	**知识库增强**	pgvector 语义检索 + RAG；Neo4j 建模「技能—岗位—题目」
3	**本地模型混合部署**	Ollama 本地小模型承接高频低成本任务，成本-质量分级推理
4	**场景拓展**	岗位族提示词模板、群面模拟、压力面试模式
5	**多端与体验**	移动端适配、实时字幕、报告对比与成长曲线

谢谢观看

AI 面试模拟系统 · 技术方案

上传简历即可开始 · AI 全程主持 · 多模态评估报告收尾

2500+ 场模拟面试 · 2300+ 道动态题目 · 400+ 条表情采样 · 17 份完整报告

© 2026 · 全部代码原创开发

朱建霖 曹钦泽 陈一涛
山西电子科技学院